

Machine Learning for Biology - Soutenance

Ilona Richard, Loïc Ledouble, Abdoulaye Tall

18 Décembre 2025

Table des matières

- ① Introduction
- ② Méthodologie
- ③ Mise en oeuvre et résultats

Table des matières

1 Introduction

2 Méthodologie

3 Mise en oeuvre et résultats

Contexte

- Des études ont montrées que les maladies inflammatoires de l'intestin (MII) s'accompagnent de perturbations des micro-organismes présents dans l'organe. L'ensemble de ces organismes représente le microbiote intestinal.
- Le séquençage ARN du microbiote permet d'identifier et de dénombrer les différentes bactéries présentes dans l'intestin.
- L'objectif est de prédire si un individu est sain ou malade à partir des données des patients, à l'aide de modèles de machine learning.

Présentation des données

- Pour chacun des p micro-organismes, on dispose de leurs abondances (OTU rares retirées).
- On dispose également des métadonnées des n patients.
- Les données s'organisent de la manière suivante :

Individu	Âge	Genre	...	OTU 1	OTU 2	...	OTU p
1	20	H	...	4010	1200	...	0
2	62	F	...	500	2650	...	2
⋮	⋮	...	⋮	⋮	⋮	⋮	⋮

- Particularité des données : grande dimension, excès de zéro, forte variabilité d'un OTU à un autre.

Table des matières

- 1 Introduction
- 2 Méthodologie**
- 3 Mise en oeuvre et résultats

Élimination des variables

- Une forêt aléatoire hiérarchise les variables selon leur importances.
- La moyenne des importances est considéré comme le seuil. Si l'importance d'une variable est en dessous, elle est retirée du jeu de données.
- Au final, le jeu de données contient **360** variables.

Modèles et algorithmes utilisés

Modèles utilisés :

- Régression logistique.
- Réseaux de neurones.
- Forêt aléatoire.
- XGBoost.

Algorithmes utilisés :

- GridSearch
- Cross-validation
- Calibration de modèles

Table des matières

- ① Introduction
- ② Méthodologie
- ③ Mise en oeuvre et résultats

Conséquence de la réduction sur les scores



Pour le réseau de neurones :

Réduction	accuracy	precision	recall	f1-score	AUC	Mean folds
Avant	0.76	0.75	0.77	0.75	0.81	0.80
Après	0.72	0.72	0.74	0.72	0.82	0.86





On constate que la réduction réduit légèrement les scores obtenus lors de l'entraînement mais la moyenne des scores sur les 5 folds est plus élevée, donc le modèle est plus généralisable à de nouvelles données.

Pour la suite, nous n'avons pas considéré la réduction de variables.

Entraînement du réseau de neurones




Courbes de calibration




Matrices de confusion


Confusion matrix LR (uncalibrated, test)




Confusion matrix NN (calibrated, test)




Confusion matrix RF (uncalibrated, test)



Confusion matrix XGB (uncalibrated, test)



Comparaison des F1 scores



Comparaison des quatre modèles


Le tableau suivant présente les moyennes des métriques, prenant en compte les deux classes.

Modèle	accuracy	precision	recall	f1-score	AUC	Mean folds
NN	0.76	0.75	0.77	0.75	0.81	0.80
LR	0.75	0.77	0.68	0.69	0.84	0.82
RF	0.76	0.78	0.69	0.70	0.76	0.81
XGB	0.71	0.69	0.67	0.67	0.80	0.81


Par la suite, nous nous intéresserons au score relatif à la classe "Disease".

Comparaison des quatre modèles


Radar des Metriques - LR




Radar des Metriques - Neural Network




Radar des Metriques - RF




Radar des Metriques - XGB



Courbes ROC



Récapitulatif Workflow



Limites de l'étude et perspectives

- Déséquilibre dans les données : peu d'individus par rapport au nombre de variables élevé.
- Déséquilibre dans les effectifs des classes.
- Impossible d'utiliser ACP ou test de Student pour la réduction des variables.